

## 17.4.17 ( 逻辑回归 )


Logistic Regression ( 逻辑回归 ) 虽然是回归算法,但在实际应用中大部分是用来Classification ( 分类 )。分类两类的,一般是1: "Positive Class" 正类,和0: "Negative Class" 负类。

Threshold classifier output at 0.5:

If Hypothesis Representation 大于等于 0.5, predict "y = 1" 【Hypothesis Representation: 假设 model】

If Hypothesis Representation 小于 0.5, predict "y = 0"


所以,二元的Logistic Regression Algorithm 中的Hypothesis Representation是在0-1 范围内。



图为: 逻辑回归模型


二元Logistic Regression Algorithm 的Hypothesis Representation又叫做Sigmoid function (S型函数) 或者Logistic function (逻辑函数)。

Hypothesis Representation输出的是在X条件下达到Y=1的概率。



上图假设函数为二元一次函数。即Hypothesis Representation是线性的,假设函数的图像就是决定边界 (Decision boundary)。


## Non-linear decision boundaries



非线性的决定边界 (Decision boundary)，即Hypothesis Representation是多项式函数。假设theta的值。此时的决定边界构成一个圆。

## Logistic regression cost function

$$\text{Cost}(\underline{h_{\theta}(x)}, y) = \begin{cases} \boxed{-\log(h_{\theta}(x))} & \text{if } y = 1 \\ \underline{-\log(1 - h_{\theta}(x))} & \text{if } y = 0 \end{cases}$$





$\rightarrow$  Cost = 0 if  $y = 1, h_{\theta}(x) = 1$   
 But as  $\frac{h_{\theta}(x) \rightarrow 0}{\text{Cost} \rightarrow \infty}$

$\rightarrow$  Captures intuition that if  $h_{\theta}(x) = 0$ ,  
 (predict  $P(y = 1|x; \theta) = 0$ ), but  $y = 1$ ,  
 we'll penalize learning algorithm by a very large cost.

## Logistic regression cost function

$$\text{Cost}(h_{\theta}(x), y) = \begin{cases} -\log(h_{\theta}(x)) & \text{if } y = 1 \\ -\log(1 - h_{\theta}(x)) & \text{if } y = 0 \end{cases}$$



Logistic Regression (逻辑回归) 算法的cost function。

前两张图是Logistic Regression (逻辑回归) 算法的cost function的具体表现，这样构建的  $\text{Cost}(h_{\theta}(x), y)$  函数的特点是：当实际的  $y=1$  且  $h_{\theta}$  也为 1 时误差为 0，当  $y=1$ ，但  $h_{\theta}$  不为 1 时误差随着  $h_{\theta}$  的变小而变大；当实际的  $y=0$  且  $h_{\theta}$  也为 0 时代价为 0，当  $y=0$ ，但  $h_{\theta}$  不为 0 时误差随着  $h_{\theta}$  的变大而变大。

## Logistic regression cost function

$$\begin{aligned} J(\theta) &= \frac{1}{m} \sum_{i=1}^m \text{Cost}(h_{\theta}(x^{(i)}), y^{(i)}) \\ &= -\frac{1}{m} \left[ \sum_{i=1}^m y^{(i)} \log h_{\theta}(x^{(i)}) + (1 - y^{(i)}) \log (1 - h_{\theta}(x^{(i)})) \right] \end{aligned}$$

To fit parameters  $\theta$  :

$$\min_{\theta} J(\theta) \quad \text{Get } \underline{\theta}$$

To make a prediction given new  $x$  :

$$\text{Output } \underline{h_{\theta}(x)} = \frac{1}{1 + e^{-\theta^T x}}$$

$$\underline{p(y=1 | x; \theta)}$$

简化的cost function如上，不用额外判断  $y$  的值。

## Gradient Descent

$$J(\theta) = -\frac{1}{m} \left[ \sum_{i=1}^m y^{(i)} \log h_{\theta}(x^{(i)}) + (1 - y^{(i)}) \log (1 - h_{\theta}(x^{(i)})) \right]$$

Want  $\min_{\theta} J(\theta)$ :

Repeat {

$$\rightarrow \theta_j := \theta_j - \alpha \sum_{i=1}^m (h_{\theta}(x^{(i)}) - y^{(i)}) x_j^{(i)}$$

(simultaneously update all  $\theta_j$ )

}

$$\Theta = \begin{bmatrix} \theta_0 \\ \theta_1 \\ \theta_2 \\ \vdots \\ \theta_n \end{bmatrix} \leftarrow \text{for } i=0 \text{ to } n$$

$$h_{\theta}(x) = \Theta^T x$$

$$h_{\theta}(x) = \frac{1}{1 + e^{-\Theta^T x}}$$

Algorithm looks identical to linear regression!

化简的逻辑回归的梯度下降公式和线性回归的表面一样，但是假设函数不一样。

```
test.m x gradientDescentMulti.m x computeCostMulti.m x normalEqn.m x costFu
1 function [jVal, gradient] = costFunction(theta)
2     jVal = (theta(1,1) - 6)^2 + (theta(2,1) - 6)^2;
3     gradient(1,1) = 2*(theta(1,1) - 6);
4     gradient(2,1) = 2*(theta(2,1) - 6);
5 end

命令行窗口
>> options = optimset('GradObj','on','MaxIter',66);
>> initialTheta = zeros(2,1);
>> [optTheta, minjVal, exitFlag] = fminunc(@costFunction, initialTheta, options)
```

高级算法求cost function 的最优值，optimset 是内置的算法结构体，fminunc是优化cost function最小值的函数。高级的，一般情况下可以替代梯度下降。