


## 17.5.1 ( SVM浅析 )

SVM 支持向量机 ( Support Vector Machines )

直观理解SVM : <https://www.zhihu.com/question/21094489>

分类就是建一个分类函数或分类模型，对未知的进行预测分类。支持向量机就是把要分类的问题用超平面进行分类。支持向量机是监督学习算法中的分类算法，比如：把二维平面上的两类点分成两类，我们就可以把这些点投影到三维空间，然后用一个超平面把他们切成两类，然后把这个切面再投影到二维平面上就是一个很好地决策分界线。




图中的三条线都能把平面内的两类给分开，但是明显的黑色的线分类效果更好，因为黑色的线是在两类中离得最近的点的中间位置，也就是距离两类中最近的点都有最远的距离，这个距离就叫做 margin，因此，支持向量机也叫做大间距分类器。

### Alternative view of logistic regression (x, y)


Cost of example:  $-(y \log h_{\theta}(x) + (1 - y) \log(1 - h_{\theta}(x)))$  ←

$$= -y \log \frac{1}{1 + e^{-\theta^T x}} - (1 - y) \log \left(1 - \frac{1}{1 + e^{-\theta^T x}}\right)$$
 ←

If  $y = 1$  (want  $\theta^T x \gg 0$ ):



If  $y = 0$  (want  $\theta^T x \ll 0$ ):



类比于逻辑回归来说，比如： $y = 1$ ，一个样本的cost 如左图，在支持向量机中，我们默认从1分开，大于1的都算它的cost 为0，小于1的部分就画一条接近逻辑回归图像的直线，这样就把SVM中 $y=1$ 情况下的cost 写出来了。当 $y=0$ 时，cost 如右图。

## Support vector machine

Logistic regression:

$$\min_{\theta} \frac{1}{m} \left[ \sum_{i=1}^m y^{(i)} \underbrace{(-\log h_{\theta}(x^{(i)}))}_{\text{cost}_1(\theta^T x^{(i)})} + (1 - y^{(i)}) \underbrace{(-\log(1 - h_{\theta}(x^{(i)})))}_{\text{cost}_0(\theta^T x^{(i)})} \right] + \frac{\lambda}{2m} \sum_{j=1}^n \theta_j^2$$

Support vector machine:

$$\min_{\theta} \cancel{\frac{1}{m}} C \sum_{i=1}^m y^{(i)} \text{cost}_1(\theta^T x^{(i)}) + (1 - y^{(i)}) \text{cost}_0(\theta^T x^{(i)}) + \frac{1 \times \cancel{2}}{2 \times \cancel{\lambda}} \sum_{j=1}^n \theta_j^2$$

$\min_u (u-5)^2 + 1 \rightarrow u=5$   
 $\min_u 10(u-5)^2 + 10 \rightarrow u=5$

$A + \lambda B \leftarrow$   
 $C \quad A + B \leftarrow \quad C = \frac{1}{\lambda}$

$$\rightarrow \min_{\theta} C \sum_{i=1}^m \left[ y^{(i)} \text{cost}_1(\theta^T x^{(i)}) + (1 - y^{(i)}) \text{cost}_0(\theta^T x^{(i)}) \right] + \frac{1}{2} \sum_{j=1}^n \theta_j^2$$


说到底，就是最小化cost问题，原来的逻辑回归函数前面的1/m变成C，后面的正则项的lambda去掉，就变成SVM的cost function。C就相当于1/lambda。C的作用就是调节两项的权重问题。

回顾  $C=1/\lambda$ ，因此：

C 较大时，相当于  $\lambda$  较小，可能会导致过拟合，高方差。

C 较小时，相当于  $\lambda$  较大，可能会导致低拟合，高偏差。

一个好的C值可以帮助SVM很好地处理异常点问题。当C非常大时就是下图中的紫红线，当C取得恰到好处时就是图中的黑线，如下图：



SVM决策边界


求cost 最优解的两个约束。

## SVM Decision Boundary

$$\min_{\theta} C \sum_{i=1}^m \left[ y^{(i)} \text{cost}_1(\theta^T x^{(i)}) + (1 - y^{(i)}) \text{cost}_0(\theta^T x^{(i)}) \right] + \frac{1}{2} \sum_{j=1}^n \theta_j^2$$


Whenever  $y^{(i)} = 1$ :

$$\theta^T x^{(i)} \geq 1$$



Whenever  $y^{(i)} = 0$ :

$$\theta^T x^{(i)} \leq -1$$





在最小化cost function的时候，我们想要让SVM的cost function的第一项为0，以便求出最优解。在此情况成立，上图中给出了两种解释。也就是在上面画出的两个cost的图像解释。由此，把SVM的cost function简化成下图：

## SVM Decision Boundary

$$\begin{aligned} \min_{\theta} \quad & \frac{1}{2} \sum_{j=1}^n \theta_j^2 \\ \text{s.t.} \quad & \theta^T x^{(i)} \geq 1 \quad \text{if } y^{(i)} = 1 \\ & \theta^T x^{(i)} \leq -1 \quad \text{if } y^{(i)} = 0 \end{aligned}$$

## Vector Inner Product



$$\rightarrow u = \begin{bmatrix} u_1 \\ u_2 \end{bmatrix} \quad \rightarrow v = \begin{bmatrix} v_1 \\ v_2 \end{bmatrix}$$

$$u^T v = ? \quad [u_1 \ u_2] \begin{bmatrix} v_1 \\ v_2 \end{bmatrix}$$

$$\|u\| = \text{length of vector } u \\ = \sqrt{u_1^2 + u_2^2} \in \mathbb{R}$$

$$\begin{aligned} p &= \text{length of projection of } v \text{ onto } u. \\ \text{Signed } u^T v &= \underline{p} \cdot \|u\| \leftarrow = v^T u \\ &= u_1 v_1 + u_2 v_2 \leftarrow p \in \mathbb{R} \end{aligned}$$

$$u^T v = p \cdot \|u\|$$

$$p < 0$$

向量内积的两种计算方式，1.用 $v$ 在 $u$ 上的投影长度 $p$ （ $p$ 是有方向的，看 $v$ 和 $u$ 的夹角）乘 $u$ 的范数（长度），或者反过来，结果是一个实数。2.是 $v$ 和 $u$ 元素对元素相乘再相加。

SVM被称为大间距分类器的原因：首先由上面两图可以把 $\theta$ 的转置乘 $x$ ，换成 $p$ 乘 $\theta$ 的范数。

求cost最小，就是求 $\theta$ 的范数最小，所以，要首先满足 $y$ 的两个限制，也就是让 $p$ 最大，才能让 $\theta$ 的范数最小。假设 $\theta_0=0$ ，也就是决策线过原点，下图左图的决策边界线所示，这个情况下，离决策线最近的样本投影到 $\theta$ 向量上的 $p$ 很小，所以为了满足上面两个限制， $\theta$ 要很大。下图右图的决策边界线所示，这个情况下，离决策线最近的样本投影到 $\theta$ 向量上的 $p$ 相对很大，所以为了满足上面两个限制， $\theta$ 要很小，也就求出了最小的cost。大边距就是让图中的margin最大。

## SVM Decision Boundary

$$\Rightarrow \min_{\theta} \frac{1}{2} \sum_{j=1}^n \theta_j^2 = \frac{1}{2} \|\theta\|^2 \leftarrow$$

$$\text{s.t. } \begin{cases} p^{(i)} \cdot \|\theta\| \geq 1 & \text{if } y^{(i)} = 1 \\ p^{(i)} \cdot \|\theta\| \leq -1 & \text{if } y^{(i)} = -1 \end{cases} \quad \left. \vphantom{\begin{matrix} p^{(i)} \cdot \|\theta\| \geq 1 \\ p^{(i)} \cdot \|\theta\| \leq -1 \end{matrix}} \right\} C \text{ vary large}$$

where  $p^{(i)}$  is the projection of  $x^{(i)}$  onto the vector  $\theta$ .

Simplification:  $\theta_0 = 0$

